

PERAMALAN HARGA SAHAM BBRI DENGAN MODEL ARIMA



Dibuat oleh:

Kelompok 12 untuk Metode Peramalan (A)

Departemen Matematika

Fakultas Matematika dan Ilmu Pengetahuan Alam

Program Studi Statistika

Depok 2023

Laporan Project Metode Peramalan (A)

Tujuan: Menganalisis suatu data runtun waktu melalui metode *Exponential Smoothing* atau model ARMA (p,q) atau ARIMA (p,d,q), melakukan analisis berdasarkan hasil yang diperoleh, dan mampu mengkomunikasikan hasil pekerjaannya secara tertulis (dalam bentuk laporan).

Tabel kontribusi kelompok:

Kelompok 12				
No.	Nama Lengkap	NPM	Persentase	Ket.
1.	Laras Kirana Anindita	2106653035	100%	Aktif berdiskusi di kelompok, mengerjakan laporan, dan melakukan pemrograman
2.	Ricky	2106724952	100%	Aktif berdiskusi di kelompok, mengerjakan laporan, dan melakukan pemrograman
3.	Wahyu Dimasdi Putra	2106704736	100%	Aktif berdiskusi di kelompok, mengerjakan laporan, dan melakukan pemrograman

1. Perumusan Masalah dan Tujuan Pengolahan Data

Saham menurut KBBI dapat diartikan sebagai surat bukti pemilikan bagian modal perseroan terbatas yang memberi hak atas dividen dan lain-lain menurut besar kecilnya modal yang disetor. Saham merupakan salah satu instrumen dalam investasi di pasar modal. Peramalan harga saham merupakan salah satu upaya yang dilakukan oleh investor untuk memprediksi pergerakan harga saham di masa mendatang. Pemahaman dan perkiraan harga saham memiliki kepentingan besar bagi para investor. Harga saham senantiasa mengalami fluktuasi seiring berjalannya waktu. Hal ini dapat disebabkan oleh, pergerakan harga saham, perubahan kondisi pasar, kejadian politik, perubahan tingkat suku bunga, dan sebagainya. Fluktuasi ini tidak stabil dan dapat berdampak signifikan jika diabaikan karena dapat menimbulkan risiko, yaitu kerugian modal.

Seiring berjalannya perkembangan waktu dan zaman, telah banyak dikembangkan berbagai metode dan pendekatan untuk digunakan peramalan harga saham di masa mendatang. Salah satunya yang akan dibahas dalam project ini adalah model menggunakan analisis *time series*, yaitu ARIMA. Model ARIMA (*Autoregressive Integrated Moving Average*) adalah model yang digunakan dalam analisis deret waktu untuk meramalkan data di masa depan. Dengan menggabungkan 3 komponen utama, yaitu *autoregressive* (AR), *integrated* (I), dan *moving average* (MA) memiliki fungsi masing-masing sebagai berikut.

- *Autoregressive*

AR menggunakan perhitungan pengaruh nilai-nilai sebelumnya dalam *time series* terhadap nilai saat ini. Model ini menggunakan hubungan linear antara nilai saat ini dengan beberapa nilai sebelumnya dalam *time series*.

- *Integrated*

Digunakan untuk mengatasi masalah nonstasioner dalam *time series* yang dimiliki dengan cara akan diubah menjadi stasioner melalui diferensiasi. Stasioner adalah

- *Moving Average*

MA menggunakan perhitungan pengaruh nilai residual pada nilai saat ini.

Model ARIMA akan dibangun untuk meramalkan nilai masa depan dalam *time series* berdasarkan pola dan tren yang terlihat dalam data historis. Model ARIMA juga memiliki asumsi yang harus dipenuhi, seperti stasioneritas dan ketiadaan pola yang kompleks. Dalam *project* ini, akan dilakukan peramalan harga saham dengan model ARIMA untuk dibandingkan dengan data harga saham sebenarnya. Data diambil dari data *historical* saham BBRI berdasarkan finance.yahoo.com/quote/BBRI.JK, dengan periode waktu 1 Desember 2003 sampai 1 Juni 2003 dengan frekuensi bulanan.

Berdasarkan latar belakang di atas, dapat dirumuskan masalah sebagai berikut.

- Bagaimana implementasi model ARIMA untuk meramalkan harga saham BBRI dan hasil analisisnya?

Tujuan pengolahan data berdasarkan rumusan masalah di atas adalah untuk implementasi model ARIMA dalam meramalkan harga saham BBRI serta interpretasi analisis yang dilakukan.

2. Metode Pengolahan Data dan Coding

Kami menggunakan data saham bulanan BBRI yang dicatat setiap tanggal 1 dari bulan Desember 2003 hingga Juli 2023. Ditampilkan 10 data pertama sebagai berikut.

	Date	Open	High	Low	Close	Adj Close	Volume
1	2003-12-01	105.0	132.5	97.5	125.0	68.38839	10635975000
2	2004-01-01	125.0	167.5	122.5	142.5	77.96275	7464990000
3	2004-02-01	142.5	165.0	135.0	155.0	84.80160	4492050000
4	2004-03-01	155.0	165.0	137.5	152.5	83.43381	4940000000
5	2004-04-01	150.0	202.5	150.0	172.5	94.37597	4260825000
6	2004-05-01	172.5	175.0	147.5	172.5	94.37597	5826845000
7	2004-06-01	170.0	170.0	147.5	167.5	91.64043	3413095000
8	2004-07-01	165.0	182.5	162.5	172.5	94.37597	2820760000
9	2004-08-01	172.5	175.0	157.5	172.5	98.56699	2274105000
10	2004-09-01	172.5	205.0	170.0	205.0	117.13757	3789385000

Showing 1 to 10 of 235 entries, 7 total columns

Keterangan:

- Date adalah tanggal, bulan, dan tahun dari data *historical*.
- Open adalah harga buka saham pada hari tersebut.
- High adalah harga tertinggi yang berfungsi sebagai *resisten*.
- Low adalah harga terendah yang berfungsi sebagai *support*.
- Close adalah harga tutup saham pada hari tersebut.
- Adj Close adalah harga penutupan yang telah disesuaikan.
- Volume adalah volume perdagangan dari saham di hari tersebut.

Sebelum *time series* dapat dimodelkan menggunakan ARIMA, perlu dilakukan pemenuhan asumsi-asumsi model ARIMA terlebih dahulu. Asumsi yang perlu dipenuhi, yaitu data *time series* harus stasioner dan pola *historical* data tidak kompleks. Pengolahan data *time series project* ini akan menggunakan bantuan *software* Rstudio.

2.1. Import Library dan Dataset

Pertama, *import* semua *packages/library* yang akan digunakan pada pengolahan data *time series* ini dengan menggunakan bantuan RStudio dan berikut adalah beberapa *library* yang digunakan.

```
library(TSA)
library(tseries)
library(forecast)
library(readxl)
library(lmtest) #for model diagnostic
```

2.2. Variabel Time Series

Setelah itu, akan dibuat variabel *time series* berdasarkan dataset yang dimiliki. Pada tahap ini akan dilihat *plot* dari *historical* data untuk melihat pola ACF dan PACF.

```
##time series variable
ts <- ts(bbri[,5],start = c(2003,12), frequency = 12)
ts
tsdisplay(ts)
```

Tabel membaca pola ACF dan PACF adalah sebagai berikut.

Model	ACF	PACF
AR (p)	Grafik menunjukkan tren menurun	Grafik akan terpotong setelah lag ke-p
MA (q)	Grafik akan terpotong setelah lag ke-q	Grafik menunjukkan tren menurun
ARMA (p,q)	Grafik menunjukkan tren menurun	Grafik menunjukkan tren menurun

Jika plot ACF dan PACF menunjukkan tren menurun, maka model tersebut merupakan model ARMA(p,q).

2.3. Differencing

Proses *differencing* dilakukan untuk mengubah *time series* yang tidak stasioner menjadi stasioner. *Differencing* melibatkan pengurangan nilai saat ini dengan nilai sebelumnya dalam data. Tujuannya adalah untuk menghilangkan tren dan pola jangka panjang dalam deret waktu. Proses ini digunakan akibat melihat analisis visual pada tahap sebelumnya, yaitu melihat pola ACF (*Autocorrelation Function*) dan PACF (*Partial Autocorrelation Function*).

```
##differencing
dts <- diff(ts,1)
tsdisplay(dts)
BoxCox.ar(ts)
```

2.4. Transforming

Transformasi digunakan dalam *time series* untuk mengubah data sehingga memenuhi asumsi atau memperbaiki karakteristik. Bertujuan untuk meningkatkan interpretasi data, menghilangkan efek tren, musiman, nonstasioner, dan memperbaiki ketergantungan serial. Dalam tahap ini, akan digunakan BoxCox Transformasi untuk menstabilkan variansi data *time series*. Nilai λ merupakan parameter lambda yang diestimasi secara empiris atau menggunakan metode *maximum likelihood*.

```
##transforming
tts <- BoxCox(ts, BoxCox.lambda(ts))
dtts <- diff(tts,1)
tsdisplay(dtts)
```

2.5. Stasioneritas

Salah satu pemenuhan asumsi model ARIMA adalah data *time series* harus stasioner. Setelah melewati tahap *differencing* satu kali dan transformasi menggunakan BoxCox, variansi data *time series* telah stabil. Maka dari itu, akan dilihat apakah data sudah stasioner.

```
#Stasioneritas
adf.test(dtts)
eacf(dtts)
```

2.5 Suggested Model

Karena melihat plot ACF dan PACF tidak terlalu jelas. Akan dilihat plot dari EACF sehingga didapatkan 3 kandidat model yang dapat digunakan.

```
#suggested model: ARIMA(0,1,0); ARIMA(0,1,1); ARIMA(1,1,1)
model1 <- Arima(tts, order = c(0,1,0), include.constant = TRUE)
model2 <- Arima(tts, order = c(0,1,1), include.constant = TRUE)
model3 <- Arima(tts, order = c(1,1,1), include.constant = TRUE)
cbind(model1, model2, model3)
```

	model1	model2	model3
coef	0.05465597	numeric,2	numeric,3
sigma2	0.1081636	0.108548	0.1049531
var.coef	0.0004602655	numeric,4	numeric,9
mask	TRUE	logical,2	logical,3
loglik	-71.30932	-71.2217	-67.06537
aic	146.6186	148.4434	142.1307
arma	integer,7	integer,7	integer,7
residuals	ts,235	ts,235	ts,235
call	expression	expression	expression
series	"tts"	"tts"	"tts"
code	0	0	0
n.cond	0	0	0
nobs	234	234	234
model	list,10	list,10	list,10
aicc	146.6706	148.5478	142.3054
bic	153.5293	158.8094	155.952
xreg	integer,235	integer,235	integer,235
x	ts,235	ts,235	ts,235
fitted	ts,235	ts,235	ts,235

Kemudian, kita dapat melihat nilai AICC yang paling kecil (minimum) untuk menghasilkan model ARIMA yang optimal yang paling mendekati nilai asli sebenarnya. Maka, berdasarkan hasil di atas model yang akan digunakan, yaitu model **ARIMA (1,1,1)**.

2.6. Model diagnostic

Diagnosis model menitikberatkan pada proses pengujian *goodness-of-fit* dari sebuah model. Terdapat dua pendekatan yang saling melengkapi, yakni analisis residual dari model yang telah di-*fit* dan analisis model yang telah di-*over parameterized*.

Tahapan pertama adalah analisis residual, yang merupakan hasil pengurangan antara data hasil prediksi terhadap data sebenarnya, di mana jika model terspesifikasi secara tepat dan estimasi parameter cukup dekat dengan nilai sebenarnya, maka residualnya akan memiliki sifat yang mirip dengan *white noise*, yakni saling bebas dan identik berdistribusi normal dengan mean 0 dan standar deviasi yang umum.

Hal ini dapat kita lihat dari plot residual terhadap waktu, yang akan menunjukkan apakah pola penyebaran residual di sekitar nol atau tidak. Setelah itu, akan dilakukan uji tambahan, yakni uji independensi Ljung-Box dan uji normalitas Jarque-Bera.

Uji Independensi Ljung-Box

Uji independensi ini bertujuan untuk menguji independensi antar residual.

- Hipotesis:
 H_0 : Tidak terdapat korelasi antar residual
 H_1 : Terdapat korelasi antar residual
- Aturan keputusan:
Tolak H_0 , jika $Q > X^2_{m,\alpha}$.
- Kesimpulan:
Jika H_0 ditolak, dapat disimpulkan bahwa terdapat korelasi antar residual sehingga model yang diestimasi kurang sesuai.

Uji Jarque-Bera

Uji normalitas Jarque-Bera ini merupakan uji asimtotik dan umumnya digunakan untuk sampel yang relatif besar.

- Hipotesis:
 H_0 : Residual berdistribusi normal
 H_1 : Residual tidak berdistribusi normal
- Aturan Keputusan:
Tolak H_0 , jika $JB > X^2_{\alpha,2}$
- Kesimpulan: Jika H_0 ditolak, dapat disimpulkan bahwa residual dari model estimasi tidak berdistribusi normal sehingga model yang diestimasi kurang sesuai.

Uji Stasioner Augmented Dickey-Fuller (ADF)

Pengujian dilakukan terhadap data *time series* untuk mengetahui apakah data tersebut stasioner atau tidak.

- Hipotesis:
 H_0 : Data tidak stasioner
 H_1 : Data stasioner
- Aturan keputusan:

Tolak H_0 jika, $p - value < \alpha$ (taraf signifikansi)

2.6.1. Model 1

Dilakukan 3 uji di atas terhadap Model 1.

```
#model1
checkresiduals(model1)
adf.test(model1$residuals)
jarque.bera.test(model1$residuals)
```

2.6.2 Model 2

Dilakukan 3 uji di atas terhadap model 2.

```
#model2
checkresiduals(model2)
adf.test(model2$residuals)
jarque.bera.test(model2$residuals)
```

2.6.3 Model 3

Dilakukan 3 uji di atas terhadap model 3.

```
#model3
checkresiduals(model3)
adf.test(model3$residuals)
jarque.bera.test(model3$residuals)
```

2.7. Overfitting Model

Setelah melakukan spesifikasi dan didapatkan model yang cukup, akan dilakukan *overfit* pada model yang sudah didapatkan, yakni menambahkan parameter pada model.

```
##overfitting
overfit_1 <- Arima(tts, order = c(1,1,0), include.constant = TRUE)
coeftest(model1)
coeftest(overfit_1)
#Estimasi parameter dari model original tidak berbeda jauh dari model overfit
```

2.8. Forecast Model

Akan dilakukan *forecast* model berdasarkan model terbaik yang didapatkan, yaitu ARIMA(0,1,0).

```
##forecast
model1forecast <- Arima(ts, order = c(0,1,0), include.constant = TRUE, lambda = BoxCox.lambda(ts))
forecast <- forecast(model1forecast, h = 5)
autoplot(forecast)
```

2.9. Cross Validation

Pada tahap ini, data runtun waktu yang sudah stasioner akan dipecah menjadi dua, yakni data *training* dan data *testing*. Hal ini dilakukan agar ketika dibandingkan, diharapkan nilai aktual masuk ke dalam interval kepercayaan nilai prediksi. Jika nilai aktual tidak masuk ke dalam interval kepercayaan nilai prediksi, dapat disimpulkan bahwa model kurang sesuai untuk digunakan sebagai model. Misal akan dilakukan *cross validation* untuk 3 bulan berdasarkan model terbaik yang didapatkan, yaitu ARIMA (0,1,0)


```
##cross validation
test <- window(ts,start = c(2023,3))
train <- window(ts,end = c(2023,2))
trainmodel <- Arima(train,order = c(0,1,0))
crossvalidation <- forecast(trainmodel, h = 3)
plot(crossvalidation)
```

3. Interpretasi dan Analisis Hasil

Setelah melakukan pengolahan data dan *coding* seperti pada di atas, akan diambil interpretasi dari setiap hasil plot dan analisis.

3.1 Variabel Time Series

Dapat terlihat *historical* data dari dataset yang dimiliki, plot ACF, serta PACF.

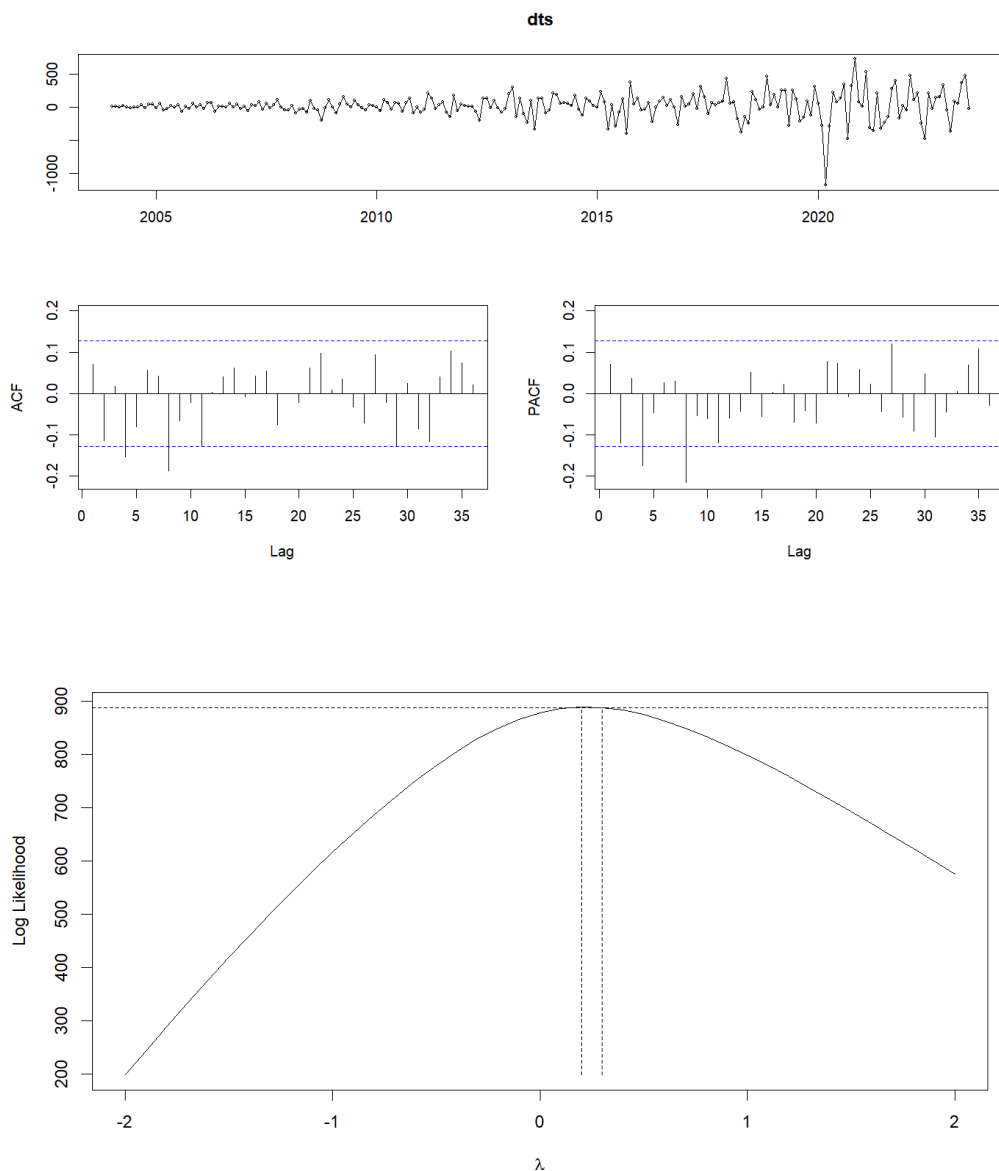


Terlihat pada plot ACF terdapat tren menurun dan pada plot ACF terdapat tiang pancang pada lag 1, maka model tersebut dapat dikatakan adalah model ARMA (p,q).

3.2. Differencing

Code berhasil di *run* tanpa *error* dan menghasilkan 2 plot.

```
> dts <- diff(ts,1)
> tsdisplay(dts)
> BoxCox.ar(ts)
```




Nilai lambda pada grafik di atas berada di antara 0.1 s.d. 0.3, dan bisa dilihat menggunakan BoxCox Lambda, diperoleh $\lambda = 0.1779195$. Untuk melihat kestasioneran data dalam varians menggunakan Box-Cox, apabila nilai lambda lebih dari 1, maka dapat dikatakan data telah stasioner dalam varians. Karena lambda diperoleh < 1 , maka data belum stasioner.

3.2 Transforming

Berdasarkan tahap sebelumnya, yaitu *differencing*. Di dapat bahwa data belum stasioner dengan nilai lambda tidak lebih dari 1. Maka dari itu, dilakukan transformasi untuk

menstabilkan variansi data *time series* dengan menggunakan metode *maximum likelihood* sebagai berikut.



Plot ACF dan PACF dapat dilihat lebih stabil setelah melewati proses *differencing* dan transformasi.

3.3. Stasioneritas

Melanjutkan pemenuhan asumsi model ARIMA, akan dilihat menggunakan Uji Augmented Dickey Fuller apakah data sudah stasioner sebagai berikut.

```
> adf.test(dtts)

Augmented Dickey-Fuller Test

data: dtts
Dickey-Fuller = -6.3725, Lag order = 6, p-value = 0.01
alternative hypothesis: stationary

Warning message:
In adf.test(dtts) : p-value smaller than printed p-value
```

Didapat $p - value = 0.01 < 0.05$ (*taraf signifikansi alpha*). Maka dari itu, H_0 ditolak sehingga data terbukti telah stasioner.

Namun, ACF dan PACF hanya efektif untuk mengidentifikasi model AR(p) dan MA(q) murni, karena untuk model ARIMA, ACF dan PACF teoritisnya mempunyai tak hingga nilai tak nol sehingga sulit untuk menentukan orde p dan q dari ACF dan PACF sampel.

Maka dari itu, akan dilihat kriteria baru yang dapat kita pakai, yaitu EACF (maupun ada alternatif lain seperti metode corner dan smallest canonical correlation (SCAN)). Selanjutnya, akan dilihat plot menggunakan EACF agar memiliki kandidat model yang diinginkan dihasilkan sebagai berikut. Tabel EACF untuk model ARMA(p,q) akan membuat pola teoritis berbentuk segitiga yang komponennya nol, dengan titik paling kiri atas adalah orde dari ARMA tersebut.

```
> eacf(dtts)
AR/MA
  0 1 2 3 4 5 6 7 8 9 10 11 12 13
0 o o o o o o o o o o o o o o
1 x o o o o o o o o o o o o
2 x x o o o o o o o o o o o
3 x x o o o o o o o o o o o
4 x x o x o o o o o o o o o
5 x x x x o o o o o o o o o
6 x x x o o o o o o o o o o
7 o x x o o o o o o o o o o
```

Berdasarkan hasil plot EACF di atas, didapatkan 3 kandidat model, yaitu:

- Model 1: ARIMA (0,1,0)

```
> eacf(dtts)
AR/MA
  0 1 2 3 4 5 6 7 8 9 10 11 12 13
0 o o o o o o o o o o o o o o
1 x o o o o o o o o o o o o
2 x x o o o o o o o o o o o
3 x x o o o o o o o o o o o
4 x x o x o o o o o o o o o
5 x x x x o o o o o o o o o
6 x x x o o o o o o o o o o
7 o x x o o o o o o o o o o
```

- Model 2: ARIMA (0,1,1)

```
> eacf(dtts)
AR/MA
  0 1 2 3 4 5 6 7 8 9 10 11 12 13
0 o o o o o o o o o o o o o o
1 x o o o o o o o o o o o o
2 x x o o o o o o o o o o o
3 x x o o o o o o o o o o o
4 x x o x o o o o o o o o o
5 x x x x o o o o o o o o o
6 x x x o o o o o o o o o o
7 o x x o o o o o o o o o o
```

- Model 3: ARIMA (1,1,1)

```
> eacf(dtts)
AR/MA
  0  1  2  3  4  5  6  7  8  9 10 11 12 13
0  o  o  o  o  o  o  o  o  o  o  o  o  o  o
1  x  o  o  o  o  o  o  o  o  o  o  o  o  o
2  x  x  o  o  o  o  o  o  o  o  o  o  o  o
3  x  x  o  o  o  o  o  o  o  o  o  o  o  o
4  x  x  o  x  o  o  o  o  o  o  o  o  o  o
5  x  x  x  x  o  o  o  o  o  o  o  o  o  o
6  x  x  x  o  o  o  o  o  o  o  o  o  o  o
7  o  x  x  o  o  o  o  o  o  o  o  o  o  o
```

3.4. Analisis diagnostic model

Melakukan 3 uji, yaitu Ljung-Box, Augmented Dickey-Fuller, dan Jarque-Bera pada setiap kandidat model yang telah diperoleh.

3.4.1 Model 1 - ARIMA (0,1,0)

```
> #model1
> checkresiduals(model1)

Ljung-Box test

data: Residuals from ARIMA(0,1,0) with drift
Q* = 19.416, df = 24, p-value = 0.7294

Model df: 0. Total lags used: 24

> adf.test(model1$residuals)


Augmented Dickey-Fuller Test

data: model1$residuals
Dickey-Fuller = -6.3886, Lag order = 6, p-value = 0.01
alternative hypothesis: stationary

Warning message:
In adf.test(model1$residuals) : p-value smaller than printed p-value
> jarque.bera.test(model1$residuals)

Jarque Bera Test

data: model1$residuals
X-squared = 67.6, df = 2, p-value = 2.109e-15
```

3.4.2 Model 2 - ARIMA (0,1,1)

```
> #model2
> checkresiduals(model2)
```

Ljung-Box test

data: Residuals from ARIMA(0,1,1) with drift
Q* = 19.223, df = 23, p-value = 0.6882

Model df: 1. Total lags used: 24

```
> adf.test(model2$residuals)
```

Augmented Dickey-Fuller Test

data: model2\$residuals
Dickey-Fuller = -6.3715, Lag order = 6, p-value = 0.01
alternative hypothesis: stationary

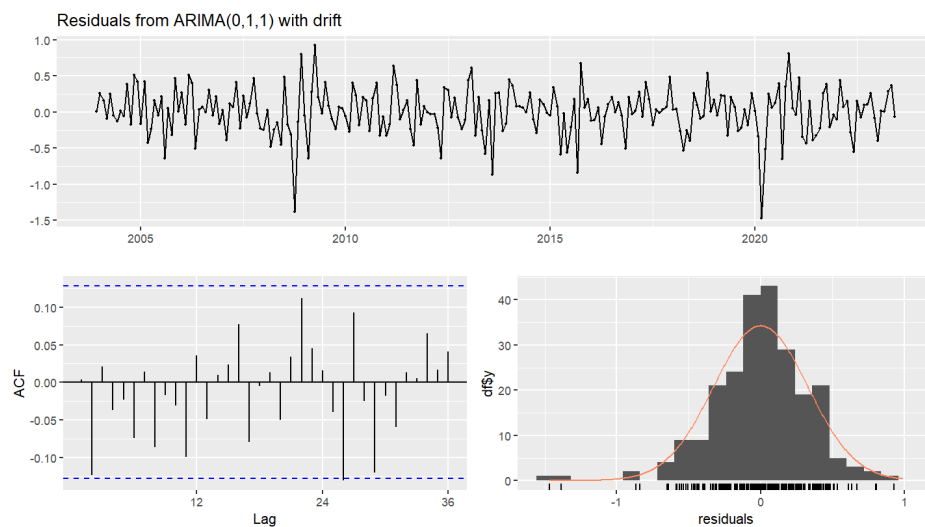
Warning message:

In adf.test(model2\$residuals) : p-value smaller than printed p-value

```
> jarque.bera.test(model2$residuals)
```

Jarque Bera Test

data: model2\$residuals
X-squared = 72.592, df = 2, p-value = 2.22e-16



3.4.3 Model 3 - ARIMA (1,1,1)

```
> #model3
> checkresiduals(model3)

Ljung-Box test

data: Residuals from ARIMA(1,1,1) with drift
Q* = 15.209, df = 22, p-value = 0.8531

Model df: 2. Total lags used: 24

> adf.test(model3$residuals)

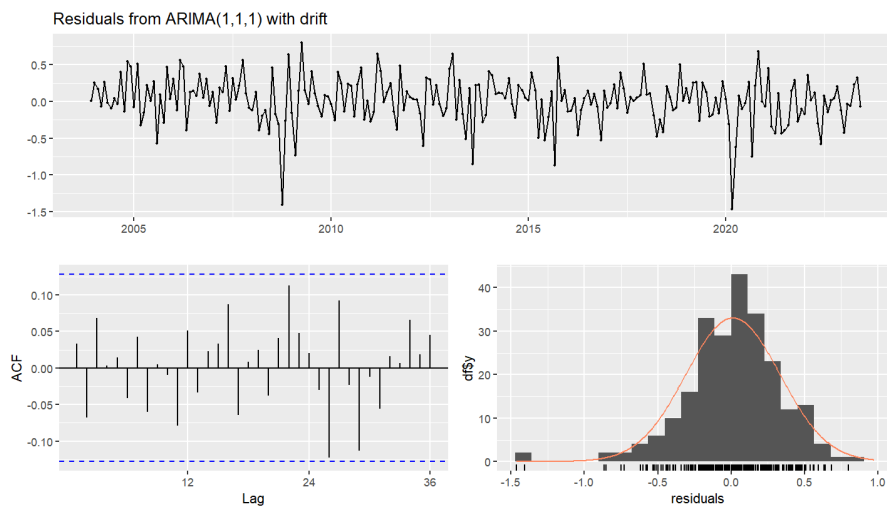
Augmented Dickey-Fuller Test

data: model3$residuals
Dickey-Fuller = -5.872, Lag order = 6, p-value = 0.01
alternative hypothesis: stationary

Warning message:
In adf.test(model3$residuals) : p-value smaller than printed p-value
> jarque.bera.test(model3$residuals)

Jarque Bera Test

data: model3$residuals
X-squared = 102.47, df = 2, p-value < 2.2e-16
```



Dari ketiga diagnostic model yang telah dilakukan didapat beberapa informasi, yaitu:

- Pada Model 1 dengan model ARIMA (0,1,0), p – $value$ pada uji Ljung-Box bernilai lebih dari α ($0,7294 > 0,05$) sehingga hipotesis nol **uji Ljung-Box tidak ditolak** yang berarti residual yang dihasilkan tidak berkorelasi antara satu periode dengan periode lainnya. Pada uji Jarque-Bera, nilai p -value yang dihasilkan sangat kecil yaitu $2,109e-15$ yang mana bernilai kurang dari α sehingga hipotesis nol uji **Jarque-Bera ditolak** sehingga residual tidak mengikuti distribusi normal. Dengan *The augmented Dickey-Fuller test* (ADF-Test) didapat p -value lebih kecil dari α ($0,01 < 0,05$) sehingga hipotesis nol ditolak yang berarti bahwa **model stasioner**.

- Pada Model 2 dengan model ARIMA (0,1,1) p -value pada uji Ljung-Box bernilai $0,6882 > \alpha=0,05$ yang membuat hipotesis nol **uji Ljung-Box tidak ditolak** yang berarti residual yang dihasilkan tidak berkorelasi antara satu periode dengan periode lainnya. Pada uji Jarque-Bera, nilai p -value yang dihasilkan sangat kecil, yaitu $2,22e-16$ yang mana bernilai kurang dari α sehingga hipotesis nol **uji Jarque-Bera ditolak** sehingga residual tidak mengikuti distribusi normal. Dengan *The augmented Dickey-Fuller test* (ADF-Test) didapat p -value lebih kecil dari α ($0,01 < 0,05$) sehingga hipotesis nol ditolak yang berarti bahwa **model stasioner**.
- Pada model 3 dengan model ARIMA (1,1,1) p -value pada uji Ljung-Box bernilai $0,8531 > \alpha=0,05$ yang membuat hipotesis nol **uji Ljung-Box tidak ditolak** yang berarti residual yang dihasilkan tidak berkorelasi antara satu periode dengan periode lainnya. Pada uji Jarque-Bera, nilai p -value yang dihasilkan sangat kecil, yaitu $2,2e-16$ yang mana bernilai kurang dari α sehingga hipotesis nol uji **Jarque-Bera ditolak** sehingga residual tidak mengikuti distribusi normal. Dengan *The augmented Dickey-Fuller test* (ADF-Test) didapat p -value lebih kecil dari α ($0,01 < 0,05$) sehingga hipotesis nol ditolak yang berarti bahwa **model stasioner**.

Jika dilihat pada kesimpulan dari ketiga model tersebut, dimana uji Ljung-Box tidak ditolak, uji Jarque-Bera ditolak, dan model stasioner. Maka, dapat disimpulkan bahwa kita dapat memilih model yang paling efisien di antaranya, yaitu model ARIMA(0,1,0) merupakan model terbaik karena memiliki tingkat (p,d,q) paling kecil.

3.5. Overfitting Model

Akan dilakukan penambahan parameter terhadap model selain yang dipilih. Namun, perhatikan bahwa untuk tidak meningkatkan model AR dan MA secara bersamaan. Digunakan ARIMA (1,1,0) untuk melakukan *overfitting* model.

```
> overfit_1 <- Arima(tts, order = c(1,1,0), include.constant = TRUE)
> coeftest(model1)
```

z test of coefficients:

	Estimate	Std. Error	z value	Pr(> z)
drift	0.054656	0.021454	2.5476	0.01085 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
> coeftest(overfit_1)
```

z test of coefficients:

	Estimate	Std. Error	z value	Pr(> z)
ar1	-0.023716	0.065310	-0.3631	0.716509
drift	0.054638	0.020953	2.6076	0.009117 **


Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Didapatkan bahwa estimasi parameter dari model original (ARIMA (0,1,0)) tidak berbeda jauh dengan model *overfit* (ARIMA(1,1,0)) sehingga kita tetap memilih model ARIMA (0,1,0).

3.6. Forecast Model

Setelah menetapkan untuk memilih model terbaik ARIMA (0,1,0), dilakukan peramalan terhadap model tersebut.

```
> model1forecast <- Arima(ts, order = c(0,1,0), include.constant = TRUE,
  lambda = BoxCox.lambda(ts))
> forecast <- forecast(model1forecast, h = 5)
> autoplot(forecast)
```




Dapat terlihat bahwa peramalan untuk waktu mendatang, grafik akan semakin naik.

3.7. Cross Validation

Didapatkan nilai *cross validation* untuk 3 bulan ke depan.

```
> ##cross validation  
> test <- window(ts,start = c(2023,3))  
> train <- window(ts,end = c(2023,2))  
> trainmodel <- Arima(train,order = c(0,1,0))  
> crossvalidation <- forecast(trainmodel, h = 3)
```



4. Koherensi Penulisan

Dalam pengolahan data untuk *forecasting* ini, dilakukan implementasi model ARIMA dalam dataset *time series* untuk harga saham BBRI. Berdasarkan pengolahan data, uji asumsi, analisis, serta peramalan untuk memprediksi harga saham pada waktu mendatang didapatkan kesimpulan bahwa model terbaik untuk *forecast* harga saham BBRI adalah model ARIMA (0,1,0).

Model ARIMA (0,1,0) sudah terbukti menjadi model paling efisien dalam meramalkan harga saham BBRI di waktu mendatang, dengan telah dibuktikan bahwa residual yang dihasilkan tidak berkorelasi antara satu periode dengan periode lainnya, residual tidak mengikuti distribusi normal, dan model yang diterapkan telah stasioner (memenuhi asumsi ARIMA).

5. Referensi

Cryer, J. D., & Chan, K. (2008). *Time series analysis: With applications in R*. Springer Science & Business Media.

Ho, S., & Xie, M. (1998). The use of ARIMA models for reliability forecasting and analysis. *Computers & Industrial Engineering*, 35(1-2), 213-216. [https://doi.org/10.1016/s0360-8352\(98\)00066-7](https://doi.org/10.1016/s0360-8352(98)00066-7)

PT bank Rakyat Indonesia (Persero) Tbk (BBRI.JK). (n.d.). Yahoo Finance - Stock Market Live, Quotes, Business & Finance News. [PT Bank Rakyat Indonesia \(Persero\) Tbk \(BBRI.JK\) Stock Price, News, Quote & History - Yahoo Finance](#)

SAHAM. (n.d.). Bursa Efek Indonesia. <https://www.idx.co.id/produk/saham/>

6. Lampiran code

```
library(TSA)
library(tseries)
library(forecast)
library(readxl)
library(lmtest) #for model diagnostic

##dataset
bbri

##time series variable
ts <- ts(bbri[,5],start = c(2003,12), frequency = 12)

##differencing
dts <- diff(ts,1)
tsdisplay(dts)
BoxCox.ar(ts)

##transforming
tts <- BoxCox(ts, BoxCox.lambda(ts))
dtts <- diff(tts,1)
tsdisplay(dtts)

adf.test(dtts)
eacf(dtts)
#suggested model: ARIMA(0,1,0); ARIMA(0,1,1); ARIMA(1,1,1)

model1 <- Arima(tts, order = c(0,1,0), include.constant = TRUE)
model2 <- Arima(tts, order = c(0,1,1), include.constant = TRUE)
model3 <- Arima(tts, order = c(1,1,1), include.constant = TRUE)
cbind(model1, model2, model3)
```

```
#dari nilai aicc, kita pilih model ARIMA(1,1,1)
```

```
##model diagnostic
```

```
#model3
```

```
checkresiduals(model3)
```

```
adf.test(model3$residuals)
```

```
jarque.bera.test(model3$residuals)
```

```
#model1
```

```
checkresiduals(model1)
```

```
adf.test(model1$residuals)
```

```
jarque.bera.test(model1$residuals)
```

```
#model2
```

```
checkresiduals(model2)
```

```
adf.test(model2$residuals)
```

```
jarque.bera.test(model2$residuals)
```

```
#Model yang memenuhi asumsi adalah model ARIMA(0,1,0)
```

```
##overfitting
```

```
overfit_1 <- Arima(tts, order = c(1,1,0), include.constant = TRUE)
```

```
coeftest(model1)
```

```
coeftest(overfit_1)
```

```
#Estimasi parameter dari model original tidak berbeda jauh dari model overfit
```

```
##forecast
```

```
model1forecast <- Arima(ts, order = c(0,1,0), include.constant = TRUE, lambda =  
BoxCox.lambda(ts))
```

```
forecast <- forecast(model1forecast, h = 5)
```

```
autoplot(forecast)
```



```
##cross validation
test <- window(ts,start = c(2023,3))
train <- window(ts,end = c(2023,2))
trainmodel <- Arima(train,order = c(0,1,0))
crossvalidation <- forecast(trainmodel, h = 3)
plot(crossvalidation)
```